

卒業研究発表会 150番

# ガウス過程に基づく逐次抽出型 $c$ -回帰モデルの検討

知能情報基礎研究室

学籍番号:1810370205

氏名:武川海斗

2022年1月24日

# 研究の概要

逐次抽出型  
 $c$ -回帰モデル

+

ガウス過程に  
基づく  $c$ -回帰  
モデル

= 提案手法

クラスタ数の自動推定    非線形な構造が得られる

# 逐次抽出型 $c$ -回帰モデル(SCRM)

$$\text{目的関数 } J_{\text{SCRM}}(\mathbf{U}, \mathbf{B}) = \sum_{k=1}^n u_{k1} (y_k - f(x_k; \beta_i))^2 + \sum_{k=1}^n u_{k0} D$$


$$\text{制約条件 } U_{\text{SCRM}} = \left\{ (u_{ki}) : u_{ki} \in \{0,1\}, \sum_{j=1}^c u_{ki} = 1, \forall k \right\}$$

$$f(x_k; \beta_i) = \sum_{j=1}^p \beta_i^j x_k^j + \beta_i^{p+1}, x \in \mathbb{R}^p, k = 1 \sim n, i = 1 \sim c$$

$(y_k - f(x_k; \beta_i))^2$  : 非類似度       $x_k$  : 説明変数

$u_{k1}$  : 抽出クラス       $y_k$  : 目的変数

$u_{k0}$  : ノイズクラス       $D > 0$  : ノイズパラメータ



非線形なクラス構造に対する  
SCRMの出力図

問題点：SCRMでは非線形な分類が困難である

# ガウス過程に基づく $c$ -回帰モデル(GPCRM)

非線形な回帰線を求めることが可能

目的関数  $J_{\text{gpcrm}}(\mathbf{U}, \mathbf{K}) = \sum_{k=1}^n \sum_{i=1}^c u_{ki} \left( y_k^{(i)} - \mathbf{k}_*^{(i)T} \mathbf{K}^{(i)-1} \mathbf{Y}^{(i)} \right)^2$


制約条件  $\sum_{i=1}^c u_{ki} = 1, (k = 1 \sim n)$

$\left( y_k^{(i)} - \mathbf{k}_*^{(i)T} \mathbf{K}_i^{-1} \mathbf{Y}_i \right)^2$  : 非類似度

$y_k$  : 目的変数       $\mathbf{K}^{(i)}$  : カーネル行列(入力点, 入力点)

$u_{ki}$  : 帰属度      ただし,  $\mathbf{K}^{(i)-1} = (\mathbf{K}^{(i)} + \lambda \mathbf{I})^{-1}$

$\mathbf{k}_*^{(i)}$  : カーネル関数(入力点, 予測したい点)



GPCRMの出力図

問題点： クラスタ数を事前に決定する必要がある

# 提案手法の定式化


SCRMとGPCRMを足し合わせた手法

SCRM

$$J_{\text{SCRM}}(\mathbf{U}, \mathbf{B}) = \sum_{k=1}^n u_{k1} (y_k - f(x_k; \beta_i))^2 + \sum_{k=1}^n u_{k0} D$$

GPCRM

$$J_{\text{gpcrm}}(\mathbf{U}, \mathbf{K}) = \sum_{k=1}^n \sum_{i=1}^c u_{ki} (y_k^{(i)} - \mathbf{k}_*^{(i)T} \mathbf{K}_i^{-1} \mathbf{Y}_i)^2$$



$$J_{\text{gpscrm}}(\mathbf{U}, \mathbf{K}) = \sum_{k=1}^n u_{k1} (y_k^{(1)} - \mathbf{k}_*^{(1)T} \mathbf{K}^{(1)-1} \mathbf{Y}^{(1)})^2 + \sum_{k=1}^n u_{k0} D$$

提案手法の目的関数

# ガウス過程に基づく逐次抽出型 $c$ -回帰モデル(GPSCRM)

目的：クラスタ数の自動推定と非線形な回帰線を得ること

目的関数  $J_{\text{gpscrm}}(\mathbf{U}, \mathbf{K}) = \sum_{k=1}^n u_{k1} (y_k^{(1)} - \mathbf{k}_*^{(1)T} \mathbf{K}^{(1)-1} \mathbf{Y}^{(1)})^2 + \sum_{k=1}^n u_{k0} D$

制約条件  $\mathbf{U}_{\text{gpscrm}} = \left\{ (u_{ki}) : u_{ki} \in \{0, 1\}, \sum_{i=0}^1 u_{ki} = 1, \forall k \right\}$

$\left( y_k^{(i)} - \mathbf{k}_*^{(1)T} \mathbf{K}^{(i)-1} \mathbf{Y}^{(i)} \right)^2$  : 非類似度     $\mathbf{k}_*^{(1)}$  : カーネル関数(入力点, 予測したい点)

$y_k$  : 目的変数

$u_{k1}$  : 抽出クラスタへの帰属度

$\mathbf{K}^{(1)}$  : 抽出クラスタに属する

$u_{k0}$  : ノイズクラスタへの帰属度

カーネル行列(入力点, 入力点)

$D > 0$  : ノイズパラメータ

ただし,  $\mathbf{K}^{(1)-1} = (\mathbf{K}^{(1)} + \lambda \mathbf{I})^{-1}$

カーネル関数にはガウスカーネルを利用




# 実験条件

目的：提案手法が**非線形な回帰線**を得られるかどうかを調べること

## データセット


- SCRM, GPCRMと比較実験
- Adjusted Rand Index(ARI)[3]で評価
- 青, 赤, 緑の順番で出力する



$n=200, c=2$


# 実験結果と考察

## GPCRM




$ARI=1.0$ ,  $\lambda=0.5$

## SCRM



$ARI=0.50$ ,  $D=1.5$

## GPSCRM



$ARI=0.80$ ,  $D=1.5$ ,  
 $\alpha=0.09$ ,  $\lambda=0.5$

回帰線が**非線形な構造**をうまく捉えられていない



# まとめ

- 結果
  - 現状の提案手法では、良好な非線形な分割が行えなかった
  - 抽出ごとにハイパーパラメータを更新する必要がある
- 今後の課題
  - 抽出ごとにハイパーパラメータを自動推定する手法を考案する

# 付録

# GPSCRMのアルゴリズム

1. ノイズパラメータ $D$ , 正則化パラメータ $\lambda$ , ガウスパラメータ $\alpha$ を設定する.
2. ランダムに帰属度 $u_{ki}$ を設定する. 収束するまで繰り返す.
  - 2.1 パラメータ $\mathbf{K}^{(1)}$ を更新する.
  - 2.2 非類似度 $d_{ki}$ を基に, 帰属度 $u_{ki}$ を更新する.
$$u_{ki} = \begin{cases} i & (d_{ki} \leq D) \\ 1 - i & (otherwise) \end{cases} \quad (i = 0, 1)$$
3.  $\{x_k \mid u_{ki} = 1\}$ の要素を $X$ から抽出する.
4.  $X = \emptyset$ の場合終了. 続行可能の場合, 2に戻る.


# ハイパーパラメータについて

- カーネルパラメータ： $\alpha$ 
  - 回帰線の形状を決定するパラメータ
  - 0.001 ~ 0.1の中から選ぶ
- ノイズパラメータ： $D$ 
  - 抽出クラスタの範囲を決定するパラメータ
  - $D=1.5$ とし，抽出するたびにノイズパラメータ $D$ を更新する
- 正則化パラメータ： $\lambda$ 
  - データの過学習を防ぐためのパラメータ
  - 0.1 ~ 2.0の中から選ぶ

$\alpha$ と $\lambda$ の組み合わせから，ARIが良好な結果を選択する


# カーネルパラメータ $\alpha$ を変えた場合

$\alpha$ を大きくした場合



GPSCRM による出力,  $D=1.5$ ,  $\alpha=5$ ,  
 $\lambda = 0.5$ , ARI = 0.027


$\alpha$ を小さくした場合



GPSCRM による出力,  $D=1.5$ ,  $\alpha=0.0001$ ,  
 $\lambda = 0.5$ , ARI = 0.97

# 正則化パラメータ $\lambda$ を変えた場合


$\lambda$ を大きくした場合



GPSCRM による出力,  $D=1.5$ ,  $\alpha=0.09$ ,

$\lambda = 4.0$ , ARI = 0.80

$\lambda$ を小さくした場合



GPSCRM による出力,  $D=1.5$ ,  $\alpha=0.09$ ,

$\lambda = 0.045$ , ARI = 0.75




# ガウス過程における期待値について

$i$ 番目のクラスタに属するデータに対するガウス過程の期待値：

$$\begin{pmatrix} \mathbf{y}^{(i)} \\ y_k^{(i)*} \end{pmatrix} \sim N \left( \mathbf{0}, \begin{pmatrix} \mathbf{K}_i & \mathbf{k}_k^{(i)} \\ \mathbf{k}_k^{(i)T} & k_{kk} \end{pmatrix} \right)$$

$$P_i \left( y_k^{(i)*} \mid x_k^{(i)*}, D_i \right) = N \left( \boxed{\mathbf{k}_k^{(i)T} \mathbf{K}_i^{-1} y^i}, \mathbf{k}_k^{**} - \mathbf{k}_{ki}^{*T} \mathbf{K}_i^{-1} \mathbf{k}_{ki}^* \right)$$



ガウス過程回帰による期待値を表す部分

$\mathbf{K}_i$ ：カーネル関数の行列


$\mathbf{k}_k^{(i)}$ ：カーネル関数のベクトル

$k_{kk}$ ：カーネル関数

# 正則化項 $\lambda$ について

- カーネル関数によって表現力の高さから過学習を引き起こす

$$P_i\left(y_k^{(i)*} \mid x_k^{(i)*}, D_i\right) = N\left(\mathbf{k}_k^{(i)T} \mathbf{K}_i^{-1} y^i, \mathbf{k}_k^{**} - \mathbf{k}_{ki}^{*T} \mathbf{K}_i^{-1} \mathbf{k}_{ki}^*\right)$$



カーネル行列に対して、正則化項を追加する

$$\mathbf{K}_i^{-1} = (\mathbf{K}_i + \lambda \mathbf{I}_{C_i})^{-1}$$